


Transformaciones ETL

Dataset Raw → Dataset Limpio

Ciencia de Datos 2026 – 5K4



Agenda

7 categorías de transformación — en orden de aplicación

- 01 Calidad y limpieza
- 02 Tipos de datos
- 03 Normalización y estandarización
- 04 Enriquecimiento / derivación
- 05 Estructura del schema
- 06 Validaciones y reglas de negocio
- 07 Estrategia de carga

1 Nulos / valores faltantes

Identificar columnas nullable.
Estrategia: drop, fill con default, impute con media/mediana, o flag `is_null`.

2 Duplicados

Detectar duplicados por clave natural del negocio (no solo PK). Deduplicar con RANK, ROW_NUMBER o DISTINCT ON.

3 Outliers

Detectar extremos con IQR o z-score. Opciones: cap/floor (winsorizar), flag para análisis posterior, o exclusión documentada.

4 Espacios y encoding

Trim() en todos los strings. Verificar UTF-8. Detectar caracteres de control invisibles (`\n`, `\t`, `\0`).

5 Caracteres especiales


Limpiar con regex: tildes, símbolos, escape. Definir si se normalizan (á→a) o se preservan.

6 Casing y homogeneidad


Aplicar UPPER/LOWER/TRIM según el dominio. Convención por campo aplicada de forma consistente.

Calidad y limpieza — Visualización

% de nulos por columna (dataset raw)



Registros: antes vs después de deduplicación



1 Casteo de tipos

Verificar que cada columna tiene el tipo correcto. Castear explícitamente `STRING` → `INT`, `FLOAT`, `BOOLEAN`, `DATE`. Validar con datos reales antes de castear.

2 Fechas y timestamps


Parsear formatos heterogéneos. Definir timezone de referencia (UTC recomendado). Separar `DATE` de `DATETIME` si aplica. Validar rangos.

3 Booleanos y flags


Estandarizar: `'Y/N'`, `'1/0'`, `'true/false'`, `'S/N'`. Convertir a `BOOLEAN` nativo o `INT(0/1)` según el motor de destino.

Tipos de datos — Visualización

Tipos de columnas detectados en dataset raw



Filas con error de casteo por columna



Normalización y estandarización

1 Valores de dominio

Identificar columnas categóricas.
Cruzar contra catálogos. Estandarizar variantes: 'ARG', 'Argentina', 'AR' → código canónico.

2 Unidades de medida


Definir unidad base por columna.
Aplicar conversiones explícitas.
Documentar fuente de tasas o factores de conversión.

3 Escalado numérico


Solo si el dato va a modelos o comparaciones. Opciones: min-max (0-1), z-score ($\mu=0$, $\sigma=1$), o log-transform para distribuciones sesgadas.

Normalización y estandarización — Visualización

Variantes del campo country_code antes de normalizar



Distribución de price_usd: raw vs escalado min-max (×100k)



* Forma idéntica, escala diferente: 0.0 – 1.0

Enriquecimiento / derivación

1

Columnas derivadas

Calcular campos nuevos: totales, ratios, extractos de fecha (año, mes, día de semana), duración entre timestamps.

2

Lookup / join externo

Cruzar contra tablas de dimensión. Manejar not found explícitamente (null, default, flag). Documentar fuente y frecuencia de actualización.


3

Metadatos de carga

Agregar siempre: `load_timestamp`, `source_system`, `batch_id`. Imprescindibles para debugging, linaje y auditoría.


Enriquecimiento / derivación — Visualización

Match rate: join contra dim_aeropuerto



■ Match OK ■ Sin match → 'DESCONOCIDO' ■ Sin match → NULL

Registros por mes — derivado de issue_date (último año)



Estructura del schema

1 Rename / alias de columnas

Aplicar convención snake_case consistente. Renombrar columnas ambiguas. Evitar nombres reservados del motor destino.

2 Selección y drop de columnas

Incluir solo las columnas necesarias.
Dropear columnas técnicas del source.
Documentar las excluidas y el motivo.

3 Pivot / unpivot

Evaluar si el layout wide debe convertirse a formato long para análisis. O viceversa para reportes pivotados.

Estructura del schema — Visualización

Comparación de schema: columnas raw vs procesadas

Columna raw	Nombre final	Tipo raw	Tipo final	Acción
CustEmailAddr	customer_email	STRING	STRING	Rename + trim + lower
DPTDATE	departure_date	STRING	DATE	Rename + casteo + tz UTC
PriceAMT	price_usd	STRING	FLOAT	Rename + casteo + validar >0
CntryCD	country_code	STRING	STRING	Rename + normalizar dominio
IsREFUNDED	is_refunded	STRING	BOOLEAN	Rename + Y/N → bool
INTERNAL_SYS_ID	—	INTEGER	—	Drop (columna interna)
PAXage	pax_age	FLOAT	INTEGER	Rename + casteo + rango 0-120
—	load_timestamp	—	TIMESTAMP	Derivada: metadato de carga

Validaciones y reglas de negocio

1 Rangos y formatos válidos

Validar rangos de negocio: fechas no futuras, montos positivos, códigos de longitud correcta. Definir acción: rechazo, corrección o flag.

2 Integridad referencial


Verificar que las FK existen en tablas de dimensión. Detectar huérfanos. Opciones: rechazar, asignar 'desconocido', o cargar y reportar.

3 Registros rechazados

Registros que no pasan van a tabla quarantine con el motivo. Nunca se descartan silenciosamente. Permite reproceso y auditoría.

Validaciones y reglas de negocio — Visualización


Waterfall de validaciones: registros que llegan al destino



Distribución de motivos en tabla quarantine

11.600

registros en quarantine



1 Full vs incremental

Full: reescribe toda la tabla.
Incremental: solo registros nuevos/modificados. Requiere watermark (timestamp o ID), o CDC.

2 Modo de escritura

Overwrite: reemplaza partición.
Append: agrega filas. MERGE (upsert): actualiza si existe, inserta si no. Elegir según patrón de datos.

3 Particionado y clustering

Definir partición antes de cargar (fecha, país, tipo). Clustering por columnas de filtro más comunes. Impacta costo y performance.

Tip de aplicación

Aplicá las capas en orden

- 1 Limpieza primero — sin datos limpios, el resto no sirve
- 2 Tipos antes de operar — nunca sumes un STRING
- 3 Lógica de negocio al final — cuando el dato ya es confiable
- 4 Guardá los rechazados — nunca los pierdas silenciosamente

Herramientas y Lineamientos

1 Notebooks

Puede ser local o google colab o la de kaggle.

Permite ir avanzando y mezclando texto con código, explicando el paso a paso del ETL desarrollado.

2 Lenguaje de programación

Python

3 Presentación 2da entrega

- Se puede presentar en la misma notebook, si esta bien formateada y se entiende lo que vamos viendo. Sino una presentación ppt o canva, etc.

- No se va a realizar un análisis del código por lo tanto no es necesario explicar código, pero si que hace cada sección de código y los hallazgos.

- Se debe subir un informe complementando la primer entrega con los puntos de la ppt mas lo que dice el enunciado del TPI